

Classificação de Dados Utilizando Sistema de Inferência Mamdani e Agrupamento Fuzzy C-Means

João Paulo da Cunha Faria

Engenharia de Computação

Centro Federal de Educação Tecnológica de Minas Gerais
Divinópolis, Minas Gerais, Brasil
joao@aluno.cefetmg.br

Joaquim César Santana da Cruz

Engenharia de Computação

Centro Federal de Educação Tecnológica de Minas Gerais
Divinópolis, Minas Gerais, Brasil
joaquim.cruz@aluno.cefetmg.br

Abstract—Este trabalho apresenta o desenvolvimento e a avaliação de um classificador baseado em lógica fuzzy utilizando o modelo de inferência de Mamdani, cujas regras linguísticas foram extraídas topologicamente através do algoritmo de agrupamento Fuzzy C-Means (FCM). Para lidar com um conjunto de dados sintético caracterizado por um desequilíbrio de classes e forte sobreposição espacial, adotou-se uma abordagem semi-supervisionada baseada em sementes de conhecimento. Esta técnica ancorou os centros de busca iniciais nas médias das classes conhecidas, visando proteger a região de domínio da classe minoritária. A otimização topológica foi validada estruturalmente pelo Coeficiente de Partição Fuzzy (FPC), que atingiu a marca de 0.77. Contudo, a avaliação de desempenho revelou uma acurácia global de 62,10%. A análise das funções de pertinência e da matriz de confusão demonstrou que o mascaramento da classe minoritária ocorreu devido à opacidade posicional dos atributos correlacionados e ao efeito de atração gravitacional exercido pelas classes majoritárias durante a convergência do agrupamento. Conclui-se que, apesar das limitações preditivas impostas pela topologia dos dados, a elevada interpretabilidade da arquitetura fuzzy revelou-se um trunfo analítico, permitindo o diagnóstico matemático exato do colapso informacional.

Index Terms—Inteligência Computacional, Lógica Fuzzy, Fuzzy C-Means, Sistema de Inferência Mamdani, Clusterização.

I. INTRODUÇÃO

A área de Inteligência Computacional tem explorado diversas abordagens para a resolução de problemas de classificação em conjuntos de dados complexos. Entre as metodologias consolidadas, os Sistemas de Inferência Fuzzy (FIS) destacam-se por sua capacidade de modelar a incerteza e a imprecisão inerentes aos dados do mundo real, fornecendo resultados altamente interpretáveis por meio de regras lógicas.

No contexto do desenvolvimento de sistemas fuzzy, um desafio recorrente é a definição da base de regras. A formulação arbitrária de regras por especialistas pode introduzir vieses e limitar a escalabilidade do modelo, especialmente em bases de dados multidimensionais. Para mitigar esse problema, técnicas de agrupamento de dados (clusterização) são frequentemente empregadas para descobrir padrões subjacentes e extrair as regras diretamente da distribuição dos dados. O algoritmo Fuzzy C-Means (FCM) mostra-se particularmente adequado para essa tarefa, pois fornece graus de pertinência contínuos que se alinham naturalmente à estrutura de um modelo FIS.

Neste cenário, o presente trabalho tem como objetivo desenvolver e avaliar um modelo de classificação fuzzy do tipo Mamdani para categorizar as amostras de uma base de dados sintética composta por seis atributos contínuos e quatro classes distintas. A metodologia proposta adota o algoritmo FCM com uma inicialização semi-supervisionada para o mapeamento e construção dos agrupamentos, a partir dos quais as regras de inferência são sistematicamente derivadas. O desempenho preditivo do sistema é validado por meio da análise de acurácia global e da matriz de confusão, o que busca demonstrar a eficácia da integração entre técnicas de agrupamento e inferência fuzzy no desenvolvimento de classificadores sem abrir mão da interpretabilidade.

II. DESCRIÇÃO DO CONJUNTO DE DADOS

O conjunto de dados utilizado neste trabalho é de natureza sintética, projetado para simular um problema de classificação multidimensional com sobreposição controlada entre classes. A base é composta por um total de 10.000 registros, estruturados em seis atributos preditores independentes e uma variável alvo categórica.

A. Características e Distribuição

Os atributos, denominados de Atributo 1 a Atributo 6, consistem em valores numéricos contínuos. A variável alvo define quatro classes distintas (Identificadores 1, 2, 3 e 4). Conforme apresentado na Fig. 1, a distribuição das classes é predominantemente equilibrada, com as classes 1, 3 e 4 representando, cada uma, 30% do total de amostras (3.000 registros por classe). A classe 2 atua como a classe minoritária, compreendendo 10% do dataset (1.000 registros).

A análise exploratória inicial não revelou a presença de valores atípicos (outliers) extremos, mas identificou a necessidade de tratamento de valores ausentes pontuais em alguns atributos, os quais foram abordados na etapa de pré-processamento. A visualização consolidada das dimensões e proporções da base permite observar a escala do problema e a densidade de amostras disponível para o treinamento dos modelos de agrupamento e inferência.

III. METODOLOGIA

Para o desenvolvimento do sistema de classificação proposto, a metodologia foi estruturada em etapas principais:




Fig. 1. Resumo estatístico e distribuição percentual das classes no conjunto de dados sintético.

i) Análise exploratória e Pré-processamento; ii) Agrupamento via algoritmo *FCM*; iii) Construção do *FIS* baseado no modelo de Mamdani; iv) Avaliação de desempenho. O modelo foi implementado na linguagem de programação *Python* em conjunto com bibliotecas da linguagem.

A. Análise Exploratória e Pré-processamento

A etapa inicial concentrou-se na preparação da base de dados sintética para garantir a integridade e a comparabilidade dos atributos. Primeiramente, realizou-se a limpeza dos dados através de uma rotina de imputação, onde valores ausentes (*NaN*) foram substituídos pela média aritmética de suas respectivas colunas, preservando as propriedades estatísticas globais do dataset.

Para mitigar a influência de atributos com escalas distintas no cálculo de distâncias do algoritmo de agrupamento, aplicou-se a técnica de padronização *Z-score*. Este procedimento reescala os dados para que possuam média zero e desvio padrão unitário, conforme equação 1:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

onde x representa o valor original, μ a média e σ o desvio padrão do atributo.

A análise visual da correlação entre os atributos, apresentada na Fig. 2, revelou uma forte interdependência linear entre a maioria das variáveis, com coeficientes de correlação frequentemente superiores a 0,80. Esta característica sugere que os dados possuem uma estrutura coesa, facilitando a identificação de agrupamentos.

Adicionalmente, o gráfico de dispersão pareado (Fig. 3) permitiu observar a distribuição das amostras no espaço de atributos. Nota-se que, apesar de existir uma sobreposição entre as fronteiras das classes, há densidades claramente distintas para cada categoria, o que justifica o emprego de uma técnica de agrupamento nebuloso para mapear essas transições suaves.

B. Agrupamento de Dados Semi-Supervisionado

A extração de padrões no espaço de características foi realizada por meio do algoritmo *FCM* [1]. O *FCM* otimiza a atribuição de graus de pertinência contínuos $u_{ik} \in [0, 1]$




Fig. 2. Matriz de correlação entre os seis atributos preditores da base de dados.




Fig. 3. Gráfico de dispersão pareado (Pairplot) exibindo a relação entre os atributos e a separação por classe.

para cada amostra x_i minimizando iterativamente a seguinte função objetivo:

$$J_m(U, V) = \sum_{k=1}^C \sum_{i=1}^N u_{ik}^m d_{ik}^2 \quad (2)$$

onde:

- U representa a matriz particional de pertinências;
- V o conjunto de protótipos espaciais (centroides) v_k ;
- m consiste no fator de fuzzificação;
- d_{ik}^2 denota a distância euclidiana ao quadrado.

Em um cenário de otimização não supervisionada padrão, a função J_m tende a concentrar os centroides nas regiões de maior densidade probabilística. Devido ao forte desbalanceamento da base do trabalho, uma inicialização estocástica faria com que a classe minoritária (10%) fosse absorvida pela atração gravitacional das classes majoritárias (30%).

Para contornar este desafio, adotou-se uma abordagem semi-supervisionada baseada em sementes de conhecimento. A abordagem consiste na não inicialização do *FCM* de forma

aleatória, os centros de busca iniciais $V^{(0)}$ foram ancorados nas médias aritméticas espaciais de cada classe conhecida no conjunto de treino:

$$v_k^{(0)} = \frac{1}{N_k} \sum_{x_i \in \text{Classe}_k} x_i \quad (3)$$

- $v_k^{(0)}$ representa o vetor de características do protótipo (centroide) inicial associado ao agrupamento k ;
- N_k denota o número total de amostras rotuladas pertencentes à classe k na partição de treinamento;
- x_i consiste no vetor de atributos contínuos da i -ésima amostra do conjunto de dados;
- Classe_k refere-se ao subconjunto de todas as amostras que compartilham o rótulo da classe k no conjunto de treino.

Esta adaptação possibilita que a classe de 10% receba um protótipo dedicado logo na iteração zero, forçando o algoritmo a mitigar a tendência de exclusão geométrica da região minoritária. A partir destas sementes, a matriz $U^{(0)}$ foi calculada e o FCM processado buscando o número de partições $C = 4$, limite de tolerância de erro de 0.005 e fator de fuzzificação $m = 2.0$.

A determinação do número ideal de agrupamentos (C) foi validada por meio do Coeficiente de Partição Fuzzy (*Fuzzy Partition Coefficient - FPC*). O *FPC* é uma métrica de validação interna que varia no intervalo $[0, 1]$, quantificando o quão nitidamente os dados foram particionados; valores mais elevados indicam agrupamentos mais densos e com menor sobreposição difusa [1].

Para definir o parâmetro, o algoritmo foi executado variando-se o número de *clusters*, e os respectivos valores de *FPC* foram extraídos. Como ilustrado na Fig. 4, o número de clusters alinhado à real cardinalidade do problema se mostrou com um *FPC* satisfatório de ≈ 0.77 .




Fig. 4. Curva do Coeficiente de Partição Fuzzy (*FPC*) em função do número de agrupamentos.

Definida a topologia de quatro partições e calculada a matriz $U^{(0)}$ a partir das sementes, o algoritmo iterativo foi

processado com o fator de fuzzificação padrão $m = 2.0$, assim como definido em sua literatura original [1]. No entanto, destaca-se que em cenários hiperespaciais desbalanceados, a manutenção deste expoente atua de forma crítica na dinâmica de atualização dos centros. Conforme evidenciado por Zhou e Yang [2], o uso do fator padrão $m = 2.0$ em distribuições assimétricas promove um espalhamento de pertinência prejudicial. Esse fenômeno sujeita os protótipos das classes minoritárias à atração gravitacional das zonas de maior densidade amostral, inviabilizando a delimitação correta das fronteiras durante a convergência, parametrizada sob o limite de tolerância de erro de 0.005.

Entretanto, mesmo comprovado na literatura que o uso do fator padrão $m = 2.0$ para distribuições assimétricas promove uma atração gravitacional das classes minoritárias [2], [3], neste presente trabalho foi constatado de forma empírica que, devido a natureza da classe minoritária (classe 2), a escolha numérica do parâmetro m sendo: i) $m = 1.5$; ii) $m = 2.0$; não alterou o comportamento de classificação da classe minoritária. Este fato pode ser constatado na matriz de confusão, figura 7, apresentada na seção de resultados.

C. Modelagem do Sistema de Inferência Mamdani

A arquitetura da base de regras foi sintetizada diretamente a partir da topologia consolidada pelo FCM, assegurando que as regras mapeassem a geometria dos dados em vez de definições arbitrárias. Cada centroide v_k final foi traduzido como o núcleo associado a uma regra linguística descrita na forma canonical:

$$\text{REGRA } k : \text{SE } x \text{ é Cluster}_k \Rightarrow y \text{ é Classe}_c$$

onde o Consequente (Classe_c) foi definido mapeando-se a categoria majoritária das amostras de treinamento que apresentaram predominância de pertinência ($\max u_{ik}$) no respectivo agrupamento k .

A máquina de inferência foi construída sob os preceitos do modelo de Mamdani. Para as amostras do conjunto de validação, a força de disparo de cada regra foi mensurada a partir da função preditiva do FCM em relação aos centros ancorados. Na etapa de agregação dos consequentes lógicos, empregou-se a S-Norma computacional do Máximo:

$$S(a, b) = \max(a, b)$$

garantindo a preservação da maior intensidade de disparo quando múltiplas regras convergiam para a mesma classe predita. Devido à impossibilidade de visualização direta do hiperespaço de seis dimensões ($\mathbb{R}^6$), a caracterização geométrica dessas funções de pertinência foi realizada isolando-se um atributo de interesse por vez, mantendo-se as demais variáveis fixadas em suas respectivas médias em relação aos centros dos agrupamentos. A operação de defuzzificação seguiu o critério do Máximo, na qual o modelo elege como saída final a classe detentora do pico mais alto na matriz agregada.

D. Avaliação de Desempenho

A capacidade preditiva e a eficácia da ancoragem por sementes foram avaliadas aplicando o conjunto isolado de validação no motor de inferência. O desempenho foi quantificado através da acurácia global e detalhado pela matriz de confusão, que permitiu verificar a robustez do modelo em preservar as fronteiras de decisão da classe minoritária sem sacrificar o ajuste nas classes majoritárias.

E. Descrição da Implementação

O sistema foi desenvolvido de forma modular na linguagem de programação *Python*, estruturado em uma pipeline de execução sequencial dividida em scripts independentes para garantir a reprodutibilidade dos experimentos. O primeiro módulo realiza a carga dos dados brutos e executa a normalização estatística via matrizes da biblioteca *Pandas*. O segundo módulo efetua a amostragem estratificada utilizando a função *train_test_split* da biblioteca *scikit-learn*, exportando os arquivos correspondentes para um diretório de saídas persistentes.

A fase de otimização geométrica foi centralizada em um terceiro script computacional, encarregado de computar as médias das sementes por agrupamento através de operações vetorizadas do *NumPy* e invocar o método *cmeans* da biblioteca *scikit-fuzzy*. Os centros matemáticos gerados nesta etapa são serializados em formato binário (.npy) para garantir consistência informacional. Por fim, o motor de inferência de Mamdani e as rotinas de visualização gráfica foram encapsulados no módulo final, que consome as matrizes armazenadas, processa a inferência fuzzy através de laços iterativos matriciais e extrai os relatórios estatísticos de classificação.

IV. RESULTADOS E DISCUSSÃO

Os resultados obtidos com a aplicação do Sistema de Inferência Mamdani foram avaliados tanto qualitativamente, por meio da análise das funções de pertinência e visualizações espaciais, quanto quantitativamente, através de métricas de classificação no conjunto de validação.

A. Análise das Funções de Pertinência

As funções de pertinência extraídas para cada um dos seis atributos preditores estão apresentadas na Fig. 5. Observa-se que as curvas para as quatro classes apresentam formatos e distribuições significativamente similares entre os diferentes atributos. Este comportamento é um reflexo direto da alta correlação linear identificada na etapa de análise exploratória (Fig. 2). Uma vez que os atributos variam de forma conjunta, os centros de massa dos agrupamentos acabam ocupando regiões análogas em cada dimensão, resultando em funções de pertinência que capturam a mesma estrutura topológica em múltiplas projeções.

B. Desempenho de Classificação

O modelo alcançou uma acurácia global de 62,10% no conjunto de validação. Embora o sistema tenha sido capaz de capturar a lógica geral de partição para as classes majoritárias,




Fig. 5. Funções de pertinência fuzzy para os seis atributos, extraídas a partir dos centros do FCM.

a análise detalhada revela limitações críticas impostas pela densidade e sobreposição dos dados. A comparação espacial entre as classes reais e as inferidas pode ser observada na Fig. 6.




Fig. 6. Visualização 3D (Atributos 2, 4 e 5) comparando as classes reais de validação com os resultados inferidos pelo modelo.

A análise quantitativa através da matriz de confusão (Fig. 7) evidencia que o sistema falhou em identificar a Classe 2, obtendo um índice de revocação (*recall*) nulo para esta categoria. Este fenômeno ocorreu porque, apesar da inicialização semi-supervisionada, o segundo centroide foi deslocado durante as iterações do FCM para uma região dominada pela Classe 1. Como consequência, o mapeamento automático de regras resultou em duas regras distintas convergindo para o mesmo consequente (Classe 1), eliminando a capacidade discriminatória do sistema em relação à classe minoritária.

Além disso, observou-se uma confusão significativa entre as classes 3 e 4, onde a sobreposição dos atributos correlacionados dificulta a definição de fronteiras fuzzy precisas. Os resultados demonstram que, para este conjunto de dados específico, a interpretabilidade fornecida pelo modelo Mamdani extraído via agrupamento enfrenta desafios de robustez quando




Fig. 7. Matriz de confusão do sistema de inferência Mamdani no conjunto de validação, evidenciando a ausência de previsões para a Classe 2.

confrontada com classes minoritárias inseridas em regiões de alta densidade de categorias concorrentes.

Um aspecto de particular relevância na análise de desempenho é a aparente divergência entre a métrica de validação interna do agrupamento e as métricas de classificação externa. Durante a fase de treinamento, o modelo atingiu um Coeficiente de Partição Fuzzy (FPC) de 0.77 para $C = 4$. Um FPC próximo à unidade indica que o algoritmo *FCM* foi bem-sucedido em encontrar partições densas, coesas e com baixa sobreposição difusa no espaço de características.

No entanto, a elevada qualidade estrutural dos agrupamentos (alto *FPC*) não se traduziu numa alta acurácia global (62,10%). Este fenômeno comprova que, devido à forte correlação inter-atributos, as classes originais do problema (em especial as Classes 1 e 2) não formam *clusters* naturais geometricamente isolados, mas sim distribuições fortemente sobrepostas no hiperespaço. O *FCM* otimizou perfeitamente os centros geométricos das massas de dados, mas o agrupamento estrutural englobou múltiplas classes categóricas sob o mesmo raio de pertinência, culminando no mascaramento da classe minoritária durante a construção do motor de inferência Mamdani.

V. CONCLUSÃO

Este trabalho apresentou o desenvolvimento de um classificador baseado em lógica fuzzy do tipo Mamdani, cuja base de regras foi extraída topologicamente através do algoritmo de agrupamento *Fuzzy C-Means* (*FCM*). Para lidar com a assimetria natural da base de dados sintética, propôs-se uma inicialização semi-supervisionada ancorada em sementes de conhecimento, visando proteger a representatividade espacial da classe minoritária.

A avaliação estrutural demonstrou que o modelo foi capaz de particionar o espaço de características com alta coesão, atingindo um Coeficiente de Partição Fuzzy (FPC) de 0.77 para quatro agrupamentos. Entretanto, o desempenho classificatório

global (acurácia de 62,10%) evidenciou limitações severas impostas pela topologia dos dados. A forte correlação linear entre os atributos gerou um alto grau de sobreposição entre as categorias, o que, somado ao espalhamento difuso provocado pelo fator de fuzzificação padrão ($m = 2.0$), resultou na migração do centroide minoritário e no mascaramento total da Classe 2.

Apesar da limitação preditiva frente à sobreposição de dados desbalanceados, a abordagem adotada provou o seu valor científico através da interpretabilidade. Diferente de modelos de aprendizado de máquina do tipo caixa-preta, a transparência das matrizes de pertinência e da composição de Mamdani permitiu rastrear e auditar geometricamente a origem do erro, diagnosticando o fenômeno de atração gravitacional entre as classes.

REFERENCES

- [1] J. C. Bezdek, *Pattern Recognition with Fuzzy Objective Function Algorithms*. New York: Plenum Press, 1981.
- [2] K. Zhou e S. Yang, "Effect of cluster size distribution on clustering: a comparative study of k-means and fuzzy c-means clustering," *Pattern Analysis and Applications*, vol. 23, pp. 1–12, 2019.
- [3] S. Askari, "Fuzzy C-Means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development," *Expert Systems with Applications*, vol. 165, p. 113856, 2021.